

TIMKoD – Lab 3

Entropie warunkowe języków naturalnych

Aleksander Staszewski

Maj 2026

1 Cel

Celem ćwiczenia było wyliczenie entropii znaków i słów oraz entropii warunkowych kolejnych rzędów dla korpusów referencyjnych i próbek `sample0.txt` - `sample5.txt`, a następnie określenie, czy próbki zawierają język naturalny.

2 Dane wejściowe i ustawienia

- Korpus angielski: `norm_wiki_en.txt`
- Korpus łaciński: `norm_wiki_la.txt`
- Pliki testowe: `sample0.txt` - `sample5.txt`
- Zakres entropii warunkowej: rzędy 1–5
- Jednostka entropii: bity

3 Metoda

Dla każdego pliku policzono:

- entropię znaków i słów,
- entropie warunkowe kolejnych rzędów (1–5) dla znaków i słów.

Ocena “czy język naturalny” była oparta na porównaniu przebiegu entropii warunkowych z korpusami referencyjnymi (angielski i łaciński), w szczególności na obserwacji spadku entropii wraz ze wzrostem rzędu modelu.

4 Wyniki

4.1 Korpusy referencyjne

Tabela 1: Entropie warunkowe znaków (bity)

Plik	$H(\text{znaki})$	$H 1$	$H 2$	$H 3$	$H 4$	$H 5$
<code>norm_wiki_en.txt</code>	4.288	3.517	3.018	2.482	2.021	1.672
<code>norm_wiki_la.txt</code>	4.228	3.450	2.823	2.152	1.643	1.313

4.2 Klasyfikacja plików sample

Tabela 2: Werdykt dla próbek

Plik	Czy język naturalny?
sample0.txt	TAK
sample1.txt	TAK
sample2.txt	TAK
sample3.txt	TAK
sample4.txt	NIE
sample5.txt	NIE

5 Wnioski

- Dla języków naturalnych entropia warunkowa maleje wraz ze wzrostem rzędu kontekstu.
- Próbki `sample0-sample3` mają przebieg entropii podobny do korpusów referencyjnych, więc zostały uznane za język naturalny.
- `sample4` wykazuje nietypowo wysokie entropie warunkowe znaków dla niższych rzędów, co wskazuje na nienaturalny charakter.
- `sample5` ma zerową entropię warunkową słów od rzędu 1, co jest nienaturalne dla zwykłego tekstu.