

TIIMKOD – Lab 5

Kompresja bezstratna (kodowanie stałodługościowe)

Aleksander Staszewski

26 maja 2026

Cel ćwiczenia

Celem zadania było zaimplementowanie kompresji i dekompresji tekstu metodą symbol-by-symbol z użyciem kodu stałej długości, wraz z zapisem i odczytem zakodowanego pliku.

Opis rozwiązania

Program w Pythonie realizuje wymagane funkcje:

- **create** – tworzy kod na podstawie alfabetu i częstości znaków,
- **encode** – koduje tekst do strumienia bitów,
- **decode** – odtwarza tekst ze strumienia bitów,
- **save** – zapisuje nagłówek (kod) i zakodowane dane do pliku binarnego,
- **load** – odczytuje kod i dane z pliku.

Poprawność została zweryfikowana przez porównanie tekstu oryginalnego z tekstem po sekwencji `encode` → `save/load` → `decode`.

Wyniki

Uruchomienie programu dla pliku `norm_wiki_sample.txt` dało:

- liczba znaków: 10 788 941,
- liczba symboli alfabetu: 37,
- długość kodu stałodługościowego: 6 bit/znak,
- poprawność kodowania/dekodowania: OK.

Rozmiary plików:

- rozmiar pliku oryginalnego: 10 788 941 B,

- rozmiar pliku zakodowanego (z kodem i reprezentacją): 8 091 957 B.

Stopień kompresji:

$$\text{packed/original} = 0.750023$$

Oszczędność miejsca:

$$(1 - 0.750023) \cdot 100\% \approx 25.00\%$$

Odpowiedzi na pytania

1) Co można zrobić, żeby bardziej skompresować tekst?

Można użyć kodów o zmiennej długości (np. Huffmana), gdzie częste symbole mają krótsze kody. Dalszą poprawę daje modelowanie kontekstu (np. bigramy, trigramy, arytmetyczne kodowanie kontekstowe), bo rozkład symboli zależy od poprzednich znaków.

2) Co z nieużyтыми kodami?

Przy 37 symbolach i długości 6 bitów dostępnych jest $2^6 = 64$ kodów, więc 27 pozostaje nieużytych. Nie niosą informacji i obniżają efektywność względem kodów dopasowanych do częstości. Można je zostawić jako rezerwę (np. znaczniki specjalne) albo przejść na kodowanie zmiennodługościowe.

3) Jak odkodowywać kody o zmiennej długości?

Należy stosować kod prefiksowy. Dekoder czyta strumień bit po bicie i schodzi po drzewie kodowym (np. drzewie Huffmana) aż do liścia odpowiadającego symbolowi. Po znalezieniu symbolu wraca do korzenia i kontynuuje odczyt.

4) Jaka jest granica wydajności kodów symbol-by-symbol?

Teoretyczną granicą jest entropia źródła H [bit/symbol]. Dla kodów prefiksowych symbol-by-symbol średnia długość kodu L spełnia:

$$H \leq L < H + 1.$$

W praktyce oznacza to, że nie da się kodować średnio krócej niż entropia bez dodatkowego modelowania/blokowania symboli.

Wnioski

Implementacja spełniła wymagania zadania: umożliwia samodzielny zapis i odczyt zakodowanych danych oraz poprawną rekonstrukcję tekstu. Dla kodowania stałodługościowego uzyskano oczekiwaną redukcję rozmiaru o około 25% względem 8-bitowego zapisu ASCII.